

Técnicas de Modelado Reducido

Ejercicio Propuesto Bloque 1. Curso 2025-26

Máster en Matemática Industrial

Resumen

Enunciado del primer ejercicio propuesto de la asignatura *Técnicas de Modelado Reducido*, correspondiente al bloque I: *(Purely) Data-driven Reduced Order Models*. En caso de duda con respecto a la interpretación de la tarea que se pide, el desarrollo de los códigos o la conveniencia de disponer de alguna referencia o material de apoyo, se puede contactar con los profesores de la asignatura a través del correo fernando.varas@upm.es.

1. Registros históricos de datos meteorológicos

El centro europeo ECMWF (European Centre for Medium-Range Weather Forecasts, www.ecmwf.int) desarrolla, entre muchas otras tareas de investigación en torno a la predicción meteorológica, un ambicioso proyecto de integración y asimilación de datos meteorológicos (tarea denominada habitualmente *reanálisis meteorológico*).




Figura 1: Página web de centro europeo ECMWF.

El último proyecto del centro ECMWF en relación con la asimilación de datos meteorológicos es el proyecto ERA5, desarrollado por Copernicus Climate Change Service (C3S) y que recoge datos desde 1940, cubriendo de este modo más de 80 años.

La base de datos ERA5 recoge valores, con frecuencia horaria, de multitud de variables meteorológicas sobre una malla estructurada de la atmósfera (tal y como se usa para los cálculos de las predicciones meteorológicas). La malla contiene 137 capas en altura (que van desde la superficie de la Tierra hasta unos 80 *km*) y las caras sobre la superficie de la Tierra tienen lados de 31 *km*. Se puede consultar información sobre las herramientas de simulación numérica en meteorología en la página www.mmm.ucar.edu/models/wrf que aloja el proyecto de desarrollo del código WRF, distribuido con una licencia de software libre y ampliamente usado en las tareas de predicción. Puede encontrarse más información en la página www2.mmm.ucar.edu/wrf/users.

Se puede encontrar información sobre el proyecto ERA5 en la página del servicio Copernicus cds.climate.copernicus.eu y también la página de UCAR (University Corporation for Atmospheric Research, consorcio de más de 100 universidades, que gestiona el centro National Center for Atmospheric Research, NCAR) climatedataguide.ucar.edu, además de la propia página del proyecto www.ecmwf.int/en/forecasts/dataset.




Figura 2: Información del proyecto ERA5 en la página web de Copernicus.




Figura 3: Información del proyecto ERA5 en la página web de UCAR.

Se pueden explorar los datos accesibles en la base de datos desde la página www.ecmwf.int/en/forecasts/dataset accediendo, desde la ventana derecha, con *Explore this dataset*. Seleccionando cualquiera de los subconjuntos de datos puede, a su vez, tenerse acceso a una API para descargar los datos (que se genera automáticamente a partir de la selección que se haya hecho).




Figura 4: Información sobre subconjuntos de datos del proyecto ERA5.




Figura 5: Plantilla de descarga de datos desde el proyecto ERA5.

Si bien siguiendo las instrucciones anteriores es posible descargar cualquier conjunto de datos, el gran volumen y la complejidad de estos datos plantea algunas dificultades, primero porque será necesario hacer una descarga masiva de datos y después porque será preciso extraer del formato correspondiente la información que se busca (por ejemplo la temperatura en la primera capa de celdas en una determinada región de la Tierra durante un cierto periodo de tiempo).

Se hace entonces más sencillo acceder a un conjunto de datos ERA5 ya preprocesados en el marco de un proyecto Google Cloud Public Datasets y disponibles en GitHub: github.com/google-research/arco-era5. Tal y como se describe en la página (ver figura 6) el acceso a través de este proyecto permite convertir la información desde el formato nativo (empleado en predicción meteorológica) a *arrays* del paquete Zarr de Python. Adicionalmente, no se hace necesario descargar los datos antes de su conversión sino que se proporciona un acceso a la estructura de datos a fin de poder explorar la información disponible antes de su descarga (y minimizar así el volumen de información que se transfiere).




Figura 6: Página web de proyecto ARCO ERA5.




Figura 7: Página web de proyecto Zarr-Python.

El siguiente código proporciona acceso a la base de datos en la variable (objeto) `ds`, que podrá ser explorada antes de decidir los datos que se desean descargar. Este acceso se hace a través del paquete `xarray` que permite una manipulación sencilla de arrays con diferentes etiquetas. Se puede encontrar información de este paquete en la página docs.xarray.dev.

Código 1: Acceso a base de datos ERA5

```
# used packages
import xarray as xr, fsspec, numpy as np

# acces to database
address = """https://storage.googleapis.com/
          gcp-public-data-arco-era5/co/
          single-level-reanalysis.zarr-v2"""

mapper = fsspec.get_mapper(address)

ds = xr.open_zarr(mapper, consolidated=True)
```

Una vez seleccionados los tiempos y las variables que se quieren extraer (deberá confirmarse previamente que están disponibles) se especificarán, así como la variable que se quiere extraer de la base de datos.

Por ejemplo, este código

Código 2: Extracción de datos

```
ds_sub = ds.sel(time=slice("2023-03-01", "2023-03-22"),
                 latitude=slice(49.2, 48.5),
                 longitude=slice(1.8, 2.8))

t2m = ds_sub["t2m"]

arr = t2m.compute().values
```

corresponde a:

- extracción del campo correspondiente a la temperatura cerca de la superficie (T a 2 m) tomada de la base ERA 5-Land, que aparece en la base de datos con la etiqueta `t2m` empleada en el acceso a `ds_sub`.
- selección de tiempos en el rango temporal establecido entre las fechas 2023-03-01 y 2023-03-22
- selección de latitudes y longitudes en los rangos especificados en los correspondientes argumentos de la llamada a `ds.sel`
- volcado de los valores pedidos en el array de salida `arr`

En cualquier caso, resulta probablemente más cómodo acudir a cualquier herramienta de IA (integrada o no en el entorno de desarrollo) para la generación de una plantilla que extraiga la información y la convierta al formato adecuado.

Debe prestarse atención a la cantidad de información que se pide extraer, pues puede ser excesivamente voluminosa. Así, la base completa ocupa 109 TB de memoria, que corresponden a:

- 38 variables representadas en cada celda
- 1323648 instantes de tiempo representados
- 542080 celdas en malla estructurada

A continuación se copia la información completa que se obtiene de la inspección de la variable `ds` obtenida del primer código.

Listado 1: Información contenida en base de datos

```
<xarray.Dataset> Size: 109TB
Dimensions:                (time: 1323648, values: 542080)
Coordinates:
  * time                    (time) datetime64[ns] 11MB 1900-01-01 ... 2050-12-31...
    valid_time              (time) datetime64[ns] 11MB dask.array<chunksize=(1323648,), meta=np.ndarray>
    latitude                (values) float64 4MB dask.array<chunksize=(542080,), meta=np.ndarray>
    longitude                (values) float64 4MB dask.array<chunksize=(542080,), meta=np.ndarray>
    depthBelowLandLayer      float64 8B ...
    entireAtmosphere         float64 8B ...
    number                  int64 8B ...
    step                    timedelta64[ns] 8B ...
    surface                  float64 8B ...
Dimensions without coordinates: values
Data variables: (12/38)
  cape                      (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  d2m                      (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  hcc                      (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  istl1                    (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  istl2                    (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  istl3                    (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  ...
  tsn                      (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  u10                      (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  u100                     (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  v10                      (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  v100                     (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
  z                        (time, values) float32 3TB dask.array<chunksize=(1, 542080), meta=np.ndarray>
Attributes: (12/14)
  Conventions:              CF-1.7
  GRIB_centre:              ecmf
  GRIB_centreDescription:   European Centre for Medium-Range Weather Forec...
  GRIB_edition:             1
  GRIB_subCentre:           0
  history:                  2023-08-27T15:04 GRIB to CDM+CF via cfgrib-0.9...
  ...
  pangeo-forge:inputs_hash: 89c3caaaaf19eb0f6e9749dbde6c93972d64419137e2c8...
  pangeo-forge:recipe_hash: 09c22f5fffc2fbe3742fbb38c8c2c761e1b41b50570f09...
  pangeo-forge:version:     0.9.5.dev2+gd43015b
  valid_time_start:         1940-01-01
  valid_time_stop:          2025-12-31
  valid_time_stop_era5t:    2026-02-28
```

2. Herramientas para desarrollo de los ejercicios propuestos

Comenzando con la visualización de datos descargados y procesados, aunque existen diversas herramientas que permiten la visualización de los datos del proyecto ERA5, así como los resultados de herramientas de predicción, (por ejemplo, github.com/anikfal/PostWRF), para la visualización de los datos posiblemente sea preferible emplear herramientas gráficas más genéricas, a fin de poder representar no solamente los datos directamente descargados sino también todos aquellos que se generen a lo largo de las tareas propuestas en el ejercicio (evitando, de este modo, tener que generar una estructura compleja para su visualización).

Por otro lado, el paquete xarray empleado en los códigos de ejemplo anteriores dispone de algunas herramientas de representación para datos bidimensionales. Es el caso de la función (método) `plot.pcolormesh` (documentada en la página docs.xarray.dev), que puede ser interesante para poder hacer una comprobación de los datos que se han descargado antes de comenzar a operar sobre ellos. A continuación se muestra un pequeño código de ejemplo (aunque, de nuevo, sea recomendable acudir a herramientas para la preparación automática de un código adaptado a las necesidades específicas).

Código 3: Representación con `xarray.plot.pcolormesh`

```
# campo 't2m' previamente extraído en variable (objeto) 'da'

plt.figure(figsize=(6,6))
ax = plt.axes(projection=ccrs.PlateCarree())
vmin = float(da.min()); vmax = float(da.max())
pcm = da.plot.pcolormesh(ax=ax, transform=ccrs.PlateCarree(),
                        cmap='coolwarm', add_colorbar=False,
                        vmin=vmin, vmax=vmax)
ax.coastlines(resolution='10m')
ax.add_feature(cfeature.BORDERS.with_scale('10m'), linewidth=0.5)
ax.set_extent([bbox[1], bbox[3], bbox[2], bbox[0]], crs=ccrs.PlateCarree())
cb = plt.colorbar(pcm, orientation='vertical', pad=0.02, aspect=30)
cb.set_label('2m_temperature_(C)')
```

En todo caso, para desarrollar el ejercicio será preferible representar los mapas bidimensionales procesados empleando las herramientas disponibles en cada entorno, lo que permitirá configurar con más libertad las representaciones.

Aunque en todos los ejemplos anteriores se ha empleado el lenguaje Python (y, sin duda, es la opción más recomendable para descargar los datos) no es obligatorio emplear este lenguaje en el desarrollo de los ejercicios propuestos. En caso de querer emplear MATLAB para la programación de las tareas que se piden en los ejercicios bastará con importar los *arrays* generados en Python desde MATLAB.

Existen (entre otras posibilidades) dos modos de leer los datos de ERA5 en MATLAB empleando las herramientas de Python previamente descritas:

- Hacer llamadas a funciones de Python directamente desde MATLAB (disponible en versiones de MATLAB desde hace varios años). Por ejemplo, la llamada a una función `get_array` implementada en un módulo `mymodule` de Python para acceder a un *array* de Python que luego se convierte al formato de MATLAB tendría una forma como la siguiente

Código 4: Ejecución de código de Python desde MATLAB

```
pyenv('Version', '/usr/bin/python3'); % optional: set Python
py_module = py.importlib.import_module('mymodule');
py_arr = py_module.get_array(); % returns a numpy array
matlab_arr = double(py_arr); % convert to MATLAB double array
```

- Guardar el *array* generado en Python en el formato nativo de MATLAB para su posterior lectura (MATLAB **no** proporciona herramientas propias para acceder al almacenamiento binario en archivos `.npy` de Python). El correspondiente código tendría un aspecto como el que sigue

Código 5: Almacenamiento de un *array* de Python en formato `.mat` de MATLAB

```
import numpy as np, scipy.io
arr = np.load('data.npy')
scipy.io.savemat('data.mat', {'A': arr})
```

3. Tareas a desarrollar en el ejercicio propuesto

A continuación se describen las tareas específicas a desarrollar en el ejercicio. Estas tareas se organizan, como se va a exponer, en tres fases relacionadas con los siguientes objetivos:

1. Compresión de la base de datos descargada (con una selección de datos de ERA5)
2. Restauración de datos incompletos o dañados

3. Propuesta de un sistema de reconstrucción de datos a partir de un conjunto limitado de medidas

En los enunciados que siguen **no** se especificará con detalle los conjuntos de datos que se seleccionarán para su descarga, dejando a los estudiantes la libertad de seleccionar los datos que, a su juicio, mejor ilustran la aplicación de las técnicas que se proponen. El elevadísimo volumen de datos en ERA5 hace, claro, altamente improbable que dos grupos trabajen sobre los mismos conjuntos de datos.

En particular, en los ejemplos mostrados acerca de la extracción de datos de la base ERA5 se ha documentado cómo obtener el campo de temperaturas cerca de la superficie (denominado temperatura a 2 metros o t_2m en la base), pensando que puede ser aquel sobre el que los estudiantes tengan más intuición facilitando, de este modo, la interpretación de los resultados. Pero, como se ha explicado, la base contiene otras 37 variables más y los estudiantes pueden escoger la que consideren más adecuada para analizar los resultados de las técnicas (incluyendo la posibilidad de considerar más de una variable).

3.1. Compresión de la base de datos descargada

En la primera tarea se considera la descarga de una base de datos seleccionando un periodo temporal y una cierta región de la Tierra, determinada por una ventana en los valores de latitud y longitud para una determinada variable (o variables, si se quiere). El volumen de datos descargado debe tener en cuenta tanto las limitaciones en tiempo de descarga como en memoria (recuérdese que el volumen total de datos es de 109 terabytes).

Dentro de esta tarea relativa a la compresión de datos se deberán incluir necesariamente (se pueden incorporar sub tareas adicionales, si se desea) las siguientes sub tareas:

- (T1.1) Descomposición en valores singulares de una base de datos bidimensional (los correspondientes parámetros se elegirían, en principio, entre longitud, latitud y tiempo) e **interpretación** de los modos obtenidos (para cada parámetro) en la descomposición.
- (T1.2) Análisis de la compresión lograda para la base de datos bidimensional en función del número de modos retenidos, ilustrando tanto el factor de compresión (reducción en la memoria con respecto a la base de datos procesada) como el error en la reconstrucción de los valores del campo.
- (T1.3) Extensión del análisis anterior a la compresión de una base de datos tridimensional (de nuevo, en principio los tres parámetros serían longitud, latitud y tiempo) mostrando factor de compresión y error de reconstrucción.
- (T1.4) Implementar una estrategia de *densificación* sobre la base de datos bidimensional considerada en las dos primeras sub tareas, de modo que se obtengan representaciones del correspondiente campo con una mayor resolución (número mayor de valores de longitud, latitud y/o tiempo) mediante el empleo de interpolación modal para los nuevos valores.

3.2. Restauración de datos incompletos o dañados

En esta segunda línea se van a emplear las técnicas de recuperación derivadas de la estrategia denominada *gappy POD* explicadas en el curso. Para ello se alterarán algunos de los datos descargados de ERA5 para examinar la capacidad de las técnicas para su restauración.

Las sub tareas mínimas a cubrir dentro de esta línea serán las siguientes:

- (T2.1) Se considerará una base de datos bidimensional alterada donde se conocen las posiciones (dentro de la base de datos) donde los valores han sido modificados y se implementará una técnica capaz de restaurarlos. Se analizará el funcionamiento de la técnica propuesta y su efectividad dependiendo de la fracción de datos que han sido modificados. Será importante discutir cómo se elige el método de reconstrucción y el número de modos empleados.
- (T2.2) Se propondrá una técnica que permita detectar qué posiciones han sido modificadas cuando (como ocurrirá en la práctica) se desconozcan dichas posiciones. Se implementará la técnica propuesta y se analizará su eficacia a la hora de detectar las posiciones donde se han modificado los datos originales.

3.3. Propuesta de un sistema de reconstrucción de datos a partir de un conjunto limitado de medidas

En esta última línea se propone explotar las *redundancias* presentes en los datos para poner a punto una técnica de reconstrucción a partir de un conjunto limitado de valores. Se trata de una aplicación de gran interés práctico desde el punto de vista de la observación pues permitiría reconstruir con detalle un cierto campo a partir de valores de ese campo en un número limitado de estaciones. En relación con la predicción, por su parte, servirá para el diseño de técnicas eficientes de

modelado reducido (basado en leyes físicas) y también para tareas denominadas de *downscaling* (que permiten describir microescalas meteorológicas a partir de predicciones regionales con una resolución espacial menor).

Se trabajará, para este apartado, con una base bidimensional donde las correspondientes variables sean latitud y longitud. Por otro lado, aunque los estudiantes pueden decidir implementar otra técnica, se sugiere emplear un algoritmo basado en el método de interpolación DEIM para la reconstrucción a partir de un número reducido de medidas.

En esta última línea se deberán completar las siguientes subtareas:

- (T3.1) Tomar una base de datos bidimensional (correspondiente a un determinado periodo temporal y donde se almacenan, para cada tiempo, los mapas de la variable considerada en función de latitud y longitud) y, a partir de ella, poner a punto una técnica que emplee la observación del campo en un número limitado de estaciones (parejas de valores de latitud y longitud) para reconstruir el campo completo. Analizar los resultados de la técnica, estudiando el error de reconstrucción cometido en función de los diferentes parámetros.
- (T3.2) Adaptar la técnica anterior para el caso en que no es posible elegir arbitrariamente las posiciones donde observar el campo, pues solamente se dispone de estaciones en determinadas regiones de la superficie (por ejemplo, no existen medidas en las zonas marinas). Para ello, se dispondrá de una matriz que indique para cada pareja de índices (que corresponderán a los valores de latitud y longitud) si se dispone o no de una estación en esa ubicación.

4. Evaluación

Los estudiantes deberán preparar un informe exponiendo el trabajo llevado a cabo en cada una de las tareas propuestas. En este informe se deberán detallar los algoritmos implementados, los resultados obtenidos al aplicar dichos algoritmos y un **análisis** de los resultados obtenidos.

Al concluir la asignatura, los grupos serán convocados para presentar los trabajos desarrollados en los tres bloques de la asignatura. En esta presentación deberán responder a las preguntas de los profesores sobre cualquiera de las actividades pedidas en cada bloque. La evaluación de la asignatura tendrá en cuenta tanto los informes presentados como la defensa durante esta sesión.